

自主科學文獻研究助理

(Autonomous Science Research Agent)

隨著大型語言模型 (Large Language Models, LLMs) 與代理系統架構 (Agentic Workflow) 的快速發展，科學研究文獻的產出速度正以指數級增長。根據最新的 AI 發展趨勢指出，「自主研究代理 (Autonomous Research Agents)」與「AI 科學家系統 (AI Scientist Systems)」已被列為新興的 DRL 核心領域與未來願景。

問題定義：在這樣的高速發展下，研究人員與學生常面臨嚴重的資訊過載問題。在進行新興領域（例如：具身智能、世界模型或多代理系統）的研究初期，研究者需要耗費大量時間檢索資料庫、閱讀海量摘要、過濾不相關文獻，並從中交叉比對以找出「研究缺口 (Research Gaps)」。傳統的文獻檢索依賴人工逐篇閱讀，效率低且容易遺漏關鍵資訊。

應用背景與使用情境：為了解決上述痛點，本設計提出「自主科學文獻研究助理系統」。使用者只需輸入一個廣泛的研究主題（例如：「強化學習在醫療 AI 與 ICU 監控的應用」），系統便會啟動自主 Agent。Agent 將自動把主題拆解為多個精確的檢索關鍵字，連線至學術資料庫擷取最新文獻，並透過自主閱讀與交叉比對，最終生成一份包含演算法比較與研究缺口的結構化文獻回顧報告。這不僅能大幅縮短文獻回顧的時間，還能提高學術研究的產出效率。

● AI Harness 系統設計

本系統採用基於大型語言模型 (LLM) 的 Agent 架構，將 LLM 視為系統的大腦 (Controller)，並結合外部工具 (Tools) 與記憶體 (Memory) 模組來完成複雜任務。整體系統架構符合現代 AI 系統設計規範。

- 核心控制器 (LLM Controller)：**選用具備強大長文本理解與 Function Calling 能力的模型（如 GPT-4o 或 Claude 3.5 Sonnet）。LLM 負責理解使用者意圖、進行多步邏輯推理 (Reasoning)，並決定在工作流的哪個階段應該調用哪個外部工具。
- 工具介面層 (Tools Interface)：**系統將外部資料庫（如 ArXiv、PubMed API）以及資料處理函式封裝為標準化工具。當 LLM 決定採取行動時，會輸出包含函數名稱與參數的 JSON 指令，交由系統攔截並執行。

- **記憶體模組 (Memory System) :**

1. **短期記憶 (Short-term Memory) :** 紀錄 Agent 在單次任務中的思考過程 (Scratchpad)、已經搜尋過的關鍵字，以及各步驟的 API 回傳結果。這能防止 Agent 重複搜尋相同的關鍵字。
2. **長期記憶 (Long-term Memory) :** 整合向量資料庫 (Vector Database)，將已分析過的論文摘要與特徵轉換為 Embedding 儲存。若未來的研究主題與過去重疊，系統可直接從長期記憶中提取知識，減少 API 呼叫成本與等待時間。

- **Tools 設計 (核心工具 API)**

為了讓 Agent 具備檢索、閱讀與分析的能力，系統設計了以下三個核心工具供 LLM 調用：

Tool 1: search_academic_papers (文獻檢索工具)

- **功能描述：**根據 LLM 拆解出的關鍵字，向學術資料庫發送檢索請求，獲取初步的論文清單。
- **輸入參數：**
 - query (string): 搜尋關鍵字 (支援布林邏輯，如 "RL AND ICU")。
 - max_results (integer): 限制回傳的論文篇數上限，避免上下文超載 (預設值為 5)。
- **回傳值：**包含 Paper ID、論文標題 (Title)、作者 (Authors) 與發布日期的 JSON 陣列。

Tool 2: extract_paper_details (論文重點擷取工具)

- **功能描述：**針對特定的論文，深入抓取其完整摘要、關鍵字與研究貢獻。
- **輸入參數：**
 - paper_id (string): 由 Tool 1 獲取的論文唯一識別碼 (如 ArXiv ID)。
- **回傳值：**論文的完整摘要文本、主要研究方法分類，以及實驗結果亮點。

Tool 3: cross_reference_analysis (交叉比對分析工具)

- **功能描述：**此工具為封裝後的特化文本分析 API (底層調用另一個專門處

理長文本摘要的 LLM 節點)。負責接收多篇論文的擷取內容，進行結構化的特徵比對，並梳理出文獻間的共同點或演算法差異。

- **輸入參數：**

- `paper_metadata_list (list)`: 包含多篇已擷取重點的論文資料物件。

- **回傳值：**Markdown 格式的綜合比較表格（例如：不同論文在資料集、演算法模型、效能指標上的比較），並附帶該分析 API 所歸納出的初步「未解研究缺口 (Research Gap)」候選清單，供主控 Agent 撰寫最終報告使用。

● Workflow / Agent 流程說明

本系統採用 **ReAct (Reasoning and Acting)** 模式進行流程控制與決策。Agent 必須遵循「思考 (Thought) → 行動 (Action) → 觀察 (Observation)」的邏輯鏈路來執行多步驟任務。具體工作流如下：

1. 任務規劃 (Task Planning)：

- **觸發：**使用者輸入「請幫我回顧最新關於多代理系統 (MARL) 在自動駕駛應用的文獻」。
- **Thought：**Agent 思考需要先將主題轉換為適合資料庫搜尋的學術關鍵字。

2. 資訊檢索 (Information Retrieval)：

- **Action：**呼叫 `search_academic_papers`，輸入 `query="MARL autonomous driving"`。
- **Observation：**系統回傳 5 篇相關論文的 ID 與標題。Agent 評估數量與關聯性是否足夠，若搜尋結果為空，則觸發錯誤恢復機制，更換關鍵字重新搜尋。

3. 深度閱讀 (Deep Reading)：

- **Thought：**需要了解這 5 篇論文的具體貢獻與演算法細節。
- **Action：**透過迴圈，依序將 5 個 Paper ID 傳入 `extract_paper_details` 工具。
- **Observation：**收集到 5 篇論文的完整摘要與研究方法。

4. 綜合分析 (Synthesis & Analysis)：

- *Thought*：資訊收集完畢，需要將這些零散的摘要統整為具備學術價值的比較。
- *Action*：將收集到的內容陣列傳入 `cross_reference_analysis` 工具。
- *Observation*：獲得包含演算法優劣勢比較的 Markdown 表格與研究缺口提示。

5. 報告生成與防呆控制 (Report Generation & Orchestration)：

- Agent 將上述所有步驟的觀察結果彙整，生成最終的自然語言回顧報告，並標註正確的文獻引用。
- *防呆機制*：系統層級設定「最大迭代次數 (Max Iterations = 10)」，若 Agent 在檢索與閱讀過程中發生無窮迴圈（例如不斷嘗試無效的關鍵字），達到上限時將強制終止，並利用現有資料生成報告，確保系統穩定性。

● Evaluation 方法（系統效果評量）

為確保 AI 系統在實際學術應用中的可靠性與準確性，本設計有別於傳統機器學習評估（如單純計算 Loss），而是針對 Agent 的行為表現與任務成效進行綜合評量，此設計佔比重為系統評估的核心部分：

1. 幻覺率 (Hallucination Rate)：

- **衡量方式**：隨機抽取系統生成的最終報告，利用人工比對或引入另一個具備 Ground Truth 存取權的 LLM（如 LLM-as-a-Judge），驗證報告中引用的論文是否真實存在，以及其對研究方法的描述是否忠於原著，避免憑空捏造學術文獻。

2. 工具調用準確率 (Tool Selection Accuracy)：

- **衡量方式**：分析 Agent 的執行 Log 紀錄。評估系統是否在正確的邏輯節點選擇對應的工具（例如：必須先呼叫檢索工具取得 ID，才能呼叫詳細擷取工具）。計算不合理調用與參數給定錯誤的發生比例。

3. 錯誤恢復率 (Error Recovery Rate)：

- **衡量方式**：故意向系統輸入極度冷門或拼寫錯誤的關鍵字，觀察 Agent 在接收到 API 回傳「查無資料 (Empty Result)」或發生「API Timeout」時，

能否自主透過 *Thought* 流程調整查詢策略（例如放寬檢索條件）並成功接續任務，而非直接崩潰中斷。

4. 任務完成度與實用性 (Task Success Rate & Utility)：

- **衡量方式：**邀請領域專家或研究人員對最終產出的「文獻比較表格」與「研究缺口分析」進行盲測評分（1-5 分）。評量該報告是否具備足夠的資訊密度，以及是否對實際開展新研究有實質幫助。